Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx` , `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

In [430…
```
ПРІЗВИЩЕ_ІМЯ = 'Паничевська Ярина Ернестівна'      # напишіть тут своє прізвище та ім'я
ГРУПА        = 'ШІ-32'
НОМЕР        = 15      # ваш номер за списком групи (1–30)

assert ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

In [431…
```
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', 60)

ВАРІАНТИ = json.load(open('lr3_variants_student.json', 'r', encoding='utf-8'))
В = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {В["варіант"]}   ·   {ПРІЗВИЩЕ_ІМЯ}   ·   {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(В['стовпці'], 1):
    print(f'   {i}. {c}')
print()
print('Ваша пара для аналізу зв’язку:', ' та '.join(В['пара']))
print()
print('Ваше додаткове питання:')
print('  ', В['питання'])
```

```
==========================================================================
ВАРІАНТ 15   ·   Паничевська Ярина Ернестівна   ·   ШІ-32
==========================================================================

Ваші вісім стовпців:
   1. Телефон
   2. Стать
   3. ступінь КТ
   4. Виписка
   5. КТ
   6. Т вище 37,5
   7. Сечов2
   8. БРпр1

Ваша пара для аналізу зв’язку: Стать та ступінь КТ

Ваше додаткове питання:
   Чому не можна обчислити коефіцієнт кореляції Пірсона між статтю та результатом лікування? Яку міру зв’язку слід узяти замість нього?
```

In [432…
```
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = В['стовпці']
```

```
print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

Out[432…

	Телефон	Стать	ступінь КТ	Виписка	КТ	Т вище 37,5	Сечов2	БРпр1
0	0958469788 дружина Ганна	ч	сердній	2022-03-10 00:00:00	20-30%	3	6.5	3.4
1	0671778486, 0994887663 дружина Оксана	ч	середній	2022-03-16 00:00:00	30-35%	3	4	2.8
2	0958768045, чоловік Степан 0951784726	ж	критичний	2022-01-18 00:00:00	70-80%	3	10.1	2.8
3	0959819331. дочка Валентина 0960845205	ж	критичний	2022-01-13 00:00:00	0.8	6	12.5	3.4
4	0952294866, дочка Дарина 0678360161	ж	NaN	2022-03-11 00:00:00	NaN	5 до гос	7.4	3.4
5	0959922983 сестра Софія	ж	середній	2021-12-26 00:00:00	30-40%	NaN	21.4	3.4
6	0998073702, дружина Наталія 0998382226	ч	важкий	2022-05-11 00:00:00	60-65%	NaN	6.1	5.1
7	0637258771, син Сергій 0968413301	ж	легкий	2022-05-28 00:00:00	до 17%	NaN	7.6	5.1

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

In [433…

```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column       Non-Null Count  Dtype  
---  ------       --------------  -----  
 0   Телефон      120 non-null    object 
 1   Стать        121 non-null    object 
 2   ступінь КТ   42 non-null     object 
 3   Виписка      120 non-null    object 
 4   КТ           44 non-null     object 
 5   Т вище 37,5  78 non-null     object 
 6   Сечов2       102 non-null    object 
 7   БРпр1        109 non-null    float64
dtypes: float64(1), object(7)
memory usage: 7.7+ KB
```

In [434…

```
# Далі — що є всередині насправді
for c in МОЇ:
```

```
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in з.map(type).value_counts().items())
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних {з.nunique()} | типи: {типи}')
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- Телефон
    непорожніх 120 з 121 | унікальних 120 | типи: str×97, int×23
    приклади: ["'0958469788 дружина Ганна'", "'0671778486, 0994887663 дружина Оксана'", "'0958768045, чоловік С
тепан 0951784726'", "'0959819331. дочка Валентина 0960845205'"]

--- Стать
    непорожніх 121 з 121 | унікальних 4 | типи: str×121
    приклади: ["'ч'", "'ж'", "'чол'", "'жін'"]

--- ступінь КТ
    непорожніх 42 з 121 | унікальних 12 | типи: str×42
    приклади: ["'сердній'", "'середній'", "'критичний'", "'важкий'"]

--- Виписка
    непорожніх 120 з 121 | унікальних 90 | типи: datetime×118, str×2
    приклади: ['datetime.datetime(2022, 3, 10, 0, 0)', 'datetime.datetime(2022, 3, 16, 0, 0)', 'datetime.dateti
me(2022, 1, 18, 0, 0)', 'datetime.datetime(2022, 1, 13, 0, 0)']

--- КТ
    непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
    приклади: ["'20-30%'", "'30-35%'", "'70-80%'", '0.8']

--- Т вище 37,5
    непорожніх 78 з 121 | унікальних 35 | типи: str×48, int×30
    приклади: ['3', '6', "'5 до гос'", "'3 дні в стац'"]

--- Сечов2
    непорожніх 102 з 121 | унікальних 66 | типи: float×79, int×22, str×1
    приклади: ['6.5', '4', '10.1', '12.5']

--- БРпр1
    непорожніх 109 з 121 | унікальних 20 | типи: float×109
    приклади: ['np.float64(3.4)', 'np.float64(2.8)', 'np.float64(5.1)', 'np.float64(4.5)']

    непорожніх 42 з 121 | унікальних 12 | типи: str×42
    приклади: ["'сердній'", "'середній'", "'критичний'", "'важкий'"]

--- Виписка
    непорожніх 120 з 121 | унікальних 90 | типи: datetime×118, str×2
    приклади: ['datetime.datetime(2022, 3, 10, 0, 0)', 'datetime.datetime(2022, 3, 16, 0, 0)', 'datetime.dateti
me(2022, 1, 18, 0, 0)', 'datetime.datetime(2022, 1, 13, 0, 0)']

--- КТ
    непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
    приклади: ["'20-30%'", "'30-35%'", "'70-80%'", '0.8']

--- Т вище 37,5
    непорожніх 78 з 121 | унікальних 35 | типи: str×48, int×30
    приклади: ['3', '6', "'5 до гос'", "'3 дні в стац'"]

--- Сечов2
    непорожніх 102 з 121 | унікальних 66 | типи: float×79, int×22, str×1
    приклади: ['6.5', '4', '10.1', '12.5']

--- БРпр1
    непорожніх 109 з 121 | унікальних 20 | типи: float×109
    приклади: ['np.float64(3.4)', 'np.float64(2.8)', 'np.float64(5.1)', 'np.float64(4.5)']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

In [435…

```
ПАСПОРТ = {
    'Телефон': ('Ідентифікатор', 'Номер телефону (часто разом з іменем родича) лише вказує на конкретну людину
    'Стать': ('Номінальна', 'Дві категорії (ч/ж) без природного порядку: значення можна лише порівняти на рівні
    'ступінь КТ': ('Порядкова', 'Рівні легкий < середній < важкий < вкрай важкий < критичний упорядковані за тя
    'Виписка': ('Інтервальна', 'Дата виписки: різниця двох дат (кількість днів) має сенс, а нуль календаря умов
    'КТ': ('Відношень', 'Відсоток ураження легеневої тканини: 0 % означає відсутність ураження (природний нуль)
```

```
    'Т вище 37,5': ('Абсолютна', 'Кількість днів із температурою понад 37,5 °C — це лічба: природний нуль (жодн
    'Сечов2': ('Відношень', 'Концентрація сечовини у повторному аналізі: нуль означає відсутність речовини'),
    'БРпр1': ('Відношень', 'Прямий білірубін у першому аналізі: природний нуль концентрації, відношення '),
}

for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))

паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
паспорт_df
```

Out[435…

	Стовпець	Шкала	Обґрунтування
0	Телефон	Ідентифікатор	Номер телефону (часто разом з іменем родича) лише вказує...
1	Стать	Номінальна	Дві категорії (ч/ж) без природного порядку: значення мож...
2	ступінь КТ	Порядкова	Рівні легкий < середній < важкий < вкрай важкий < критич...
3	Виписка	Інтервальна	Дата виписки: різниця двох дат (кількість днів) має сенс...
4	КТ	Відношень	Відсоток ураження легеневої тканини: 0 % означає відсутн...
5	Т вище 37,5	Абсолютна	Кількість днів із температурою понад 37,5 °C — це лічба:...
6	Сечов2	Відношень	Концентрація сечовини у повторному аналізі: нуль означає...
7	БРпр1	Відношень	Прямий білірубін у першому аналізі: природний нуль конце...

In [436…

```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for c in МОЇ:
    ш, об = ПАСПОРТ[c]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{c}: шкалу «{ш}» не розпізнано'
    assert len(об.strip()) >= 25, f'{c}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.')
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

In [437…

```
import re

РІВНІ_КТ = ['легкий', 'середній', 'важкий', 'вкрай важкий', 'критичний']


def числа(x):
    """дістаємо числа з тексту"""
    return [float(n) for n in re.findall(r'\d+\.?\d*', str(x))]


def стать(x):
    x = x.strip()
    if x.startswith('чол'): return 'ч'
    elif x.startswith('жін'): return 'ж'
    return x


def ступінь(x):
    if pd.isna(x):
        return None
```

```
    x = x.strip()
    if x.startswith('сер'): return 'середній'
    if x == 'легка': return 'легкий'
    return x


def кт(x):
    if isinstance(x, float):
        return x * 100
    ч = числа(x)
    #якщо у нас діапазон, то беремо середнє
    return np.mean(ч) if ч else None


def дні(x):
    if isinstance(x, int):
        return x
    ч = числа(x)
    # для випадку, якщо у тексті написано щось на кшталт: 5 днів до госп+3 дні в стац
    return sum(ч) if ч else None


def clean_data(df):
    чисті_дані = df.copy()
    чисті_дані['Телефон'] = df['Телефон']
    чисті_дані['Стать'] = df['Стать'].apply(стать)
    чисті_дані['ступінь КТ'] = pd.Categorical(df['ступінь КТ'].apply(ступінь), categories=PIBHI_KT, ordered=Tru
    чисті_дані['Виписка'] = pd.to_datetime(df['Виписка'], errors='coerce')
    чисті_дані['КТ'] = df['КТ'].apply(кт)
    чисті_дані['Т вище 37,5'] = df['Т вище 37,5'].apply(дні)
    чисті_дані['Сечов2'] = pd.to_numeric(df['Сечов2'], errors='coerce')
    чисті_дані['БРпр1'] = df['БРпр1']
    return чисті_дані

df = clean_data(df)
```

In [438…

```
def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    if ш in ('ідентифікатор',):
        return р

    #для всіх шкал вимірювань
    р['мода'] = з.mode()[0]
    р['частоти'] = з.value_counts().to_dict()

    if ш == 'номінальна':
        return р

    if ш == 'порядкова':
        коди = з.astype(str).map(PIBHI_KT.index)
        р['Q1'] = PIBHI_KT[int(коди.quantile(0.25, interpolation='lower'))]
        р['Q2 (медіана)'] = PIBHI_KT[int(коди.quantile(0.50, interpolation='lower'))]
        р['Q3'] = PIBHI_KT[int(коди.quantile(0.75, interpolation='lower'))]
        return р

    #для шкали інтервальна і вище
    р['середнє'] = з.mean()
    р['ст. відхилення'] = з.std()
    р['Q1'] = з.quantile(0.25)
    р['Q2 (медіана)'] = з.median()
    р['Q3'] = з.quantile(0.75)

    if ш in ('відношень', 'абсолютна'):
        р['CV'] = з.std() / з.mean() * 100
    return р
```

In [439…

```
def гарно(значення):
    if isinstance(значення, pd.Timestamp):
        return значення.strftime('%d.%m.%Y')
    if isinstance(значення, pd.Timedelta):
        return f'{значення.days} днів'
    if isinstance(значення, float):
        return str(round(значення, 2))
```

```
    return str(значення)


for с in МОЇ:
    шкала = ПАСПОРТ[с][0]
    р = допустима_статистика(с, шкала)
    print(f'Колонка: {с}  Шкала вимірювання: {шкала}')
    for назва, значення in р.items():
        if назва == 'частоти':
            топ = list(значення.items())[:5]
            текст = ', '.join(f'{гарно(k)}: {v}' for k, v in топ)
            if len(значення) > 5:
                текст += f'  … ще {len(значення) - 5}'
            print(f' {"частоти":<16}{текст}')
        else:
            print(f' {назва:<16}{гарно(значення)}')
    print()
```

```
Колонка: Телефон  Шкала вимірювання: Ідентифікатор
 непорожніх      120
 унікальних      120

Колонка: Стать  Шкала вимірювання: Номінальна
 непорожніх      121
 унікальних      2
 мода            ж
 частоти         ж: 75, ч: 46

Колонка: ступінь КТ  Шкала вимірювання: Порядкова
 непорожніх      42
 унікальних      5
 мода            середній
 частоти         середній: 18, важкий: 10, легкий: 7, вкрай важкий: 4, критичний: 3
 Q1              середній
 Q2 (медіана)    середній
 Q3              важкий

Колонка: Виписка  Шкала вимірювання: Інтервальна
 непорожніх      118
 унікальних      88
 мода            07.09.2021
 частоти         07.09.2021: 3, 06.06.2022: 3, 06.04.2022: 3, 19.11.2021: 3, 11.09.2021: 3  … ще 83
 середнє         29.01.2022
 ст. відхилення  109 днів
 Q1              16.11.2021
 Q2 (медіана)    15.03.2022
 Q3              27.04.2022

Колонка: КТ  Шкала вимірювання: Відношень
 непорожніх      43
 унікальних      21
 мода            30.0
 частоти         30.0: 7, 25.0: 6, 80.0: 3, 70.0: 3, 75.0: 2  … ще 16
 середнє         42.5
 ст. відхилення  21.97
 Q1              26.25
 Q2 (медіана)    35.0
 Q3              63.75
 CV              51.69

Колонка: Т вище 37,5  Шкала вимірювання: Абсолютна
 непорожніх      78
 унікальних      10
 мода            3.0
 частоти         3.0: 29, 2.0: 12, 5.0: 9, 4.0: 9, 7.0: 6  … ще 5
 середнє         4.22
 ст. відхилення  2.4
 Q1              3.0
 Q2 (медіана)    3.0
 Q3              5.0
 CV              56.89

Колонка: Сечов2  Шкала вимірювання: Відношень
 непорожніх      101
 унікальних      65
 мода            4.9
 частоти         5.0: 4, 4.9: 4, 6.5: 3, 6.2: 3, 7.1: 3  … ще 60
 середнє         10.2
 ст. відхилення  13.27
 Q1              5.9
 Q2 (медіана)    7.3
 Q3              10.0
 CV              130.16

Колонка: БРпр1  Шкала вимірювання: Відношень
 непорожніх      109
 унікальних      20
 мода            3.4
 частоти         3.4: 40, 5.1: 29, 6.8: 18, 8.5: 3, 5.0: 2  … ще 15
 середнє         4.8
 ст. відхилення  1.58
 Q1              3.4
 Q2 (медіана)    5.1
 Q3              5.3
 CV              32.81
```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

In [440…
```
df[МОЇ].describe(include='all').T
```

Out[440…

	count	unique	top	freq	mean	min	25%	50%	75%	max	std
Телефон	120	120	0958469788 дружина Ганна	1	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Стать	121	2	ж	75	NaN	NaN	NaN	NaN	NaN	NaN	NaN
ступінь КТ	42	5	середній	18	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Виписка	118	NaN	NaN	NaN	2022-01-29 18:06:06.101694976	2021-04-27 00:00:00	2021-11-16 18:00:00	2022-03-15 00:00:00	2022-04-27 18:00:00	2022-06-22 00:00:00	NaN
КТ	43.0	NaN	NaN	NaN	42.5	5.0	26.25	35.0	63.75	80.0	21.966154
Т вище 37,5	78.0	NaN	NaN	NaN	4.217949	1.0	3.0	3.0	5.0	14.0	2.399391
Сечов2	101.0	NaN	NaN	NaN	10.198614	3.4	5.9	7.3	10.0	116.0	13.274622
БРпр1	109.0	NaN	NaN	NaN	4.801468	2.4	3.4	5.1	5.3	10.2	1.575191

In [441…
```
стать_1 = df['Стать'].map({'ч': 0, 'ж': 1}).mean()
стать_2 = df['Стать'].map({'ч': 1, 'ж': 0}).mean()

ступінь = df['ступінь КТ'].dropna().astype(str).map(PIBHI_KT.index) + 1
сер_ступінь = ступінь.mean()

вип = df['Виписка'].dropna()
дні_1970 = (вип - pd.Timestamp('1970-01-01')).dt.days
дні_2021 = (вип - pd.Timestamp('2021-01-01')).dt.days
cv_1970 = дні_1970.std() / дні_1970.mean() * 100
cv_2021 = дні_2021.std() / дні_2021.mean() * 100

БЕЗГЛУЗДІ = [
    ('Телефон', 'top і freq', 'top = 0958469788 дружина Ганна, freq = 1', 'Мода ідентифікатор загалом безглузда

    ('ступінь КТ', 'середнє рангів 1–5 (1-лекий, 2-середній і тд)', f'{сер_ступінь:.2f}',
     'Ступінь «2,48» не існує серед ступенів КТ'),

    ('Стать', 'середнє кодів', f'{стать_1:.2f} (ч=0, ж=1) або {стать_2:.2f} (ч=1, ж=0)', 'Коди 0 і 1 обрано дов

    ('Виписка', 'коефіцієнт варіації', f'{cv_1970:.2f} % (від 1970) або {cv_2021:.1f} % (від 2021)',
     'Коефіцієнт варіації ділить розкид на середнє. Для дат середнє залежить від того, з якого дня ми почали ві
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення', 'Чому безглузде'])
```

Out[441…

	Стовпець	Статистика	Значення	Чому безглузде
0	Телефон	top і freq	top = 0958469788 дружина Ганна, freq = 1	Мода ідентифікатор загалом безглузда
1	ступінь КТ	середнє рангів 1–5 (1-лекий, 2-середній і тд)	2.48	Ступінь «2,48» не існує серед ступенів КТ
2	Стать	середнє кодів	0.62 (ч=0, ж=1) або 0.38 (ч=1, ж=0)	Коди 0 і 1 обрано довільно: поміняли місцями — отримали ...
3	Виписка	коефіцієнт варіації	0.58 % (від 1970) або 27.8 % (від 2021)	Коефіцієнт варіації ділить розкид на середнє. Для дат се...

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

In [442…
```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or '(визначте самостійно)')
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or '(визначте самостійно)')
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: Стать × ступінь КТ

Стать: шкала — Номінальна
ступінь КТ: шкала — Порядкова

  Стать ступінь КТ
0     ч   середній
1     ч   середній
2     ж  критичний
3     ж  критичний
4     ж        NaN
5     ж   середній
```

In [443…
```
ОБРАНА_МІРА = 'Коефіцієнт крамера (V)'
ЧОМУ_САМЕ_ВОНА = "У мене для колонки стать - номінальна шкала, для колонки ступінь КТ - порядкова. Коеціфієнт к

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'
```

In [444…
```
from scipy.stats import chi2_contingency

def критерій_крамера(df):
    chi2, p, dof, очік = chi2_contingency(df, correction=False)
    n = df.to_numpy().sum()
    V = np.sqrt(chi2 / (n * (min(df.shape) - 1)))
    return chi2, p, dof, V, очік
```

In [445…
```
#беремо лише пацієнтів, у яких непусті ці дві колонки
табл = pd.crosstab(df['Стать'], df['ступінь КТ'])
табл
```

Out[445…

Стать \ ступінь КТ	легкий	середній	важкий	вкрай важкий	критичний
ж	4	8	4	2	3
ч	3	10	6	2	0

In [446…
```
chi2, p, dof, V, очік = критерій_крамера(табл)

print('Очікувана таблиця (якби зв\'язку не було):')
print(pd.DataFrame(очік, index=табл.index, columns=табл.columns).round(1))
print()
print(f'Пацієнтів у таблиці: {табл.to_numpy().sum()}')
print(f'χ² = {chi2:.2f}')
```

```
print(f'p = {p:.3f}')
print(f'V Крамера = {V:.2f}')
```

```
Очікувана таблиця (якби зв'язку не було):
ступінь КТ  легкий  середній  важкий  вкрай важкий  критичний
Стать
ж              3.5       9.0     5.0           2.0        1.5
ч              3.5       9.0     5.0           2.0        1.5

Пацієнтів у таблиці: 42
χ² = 3.77
p = 0.439
V Крамера = 0.30
```

Нотатки:

p - дає відповідь на питання: "якби між нашими двома ознаками взагалі не було зв'язку, яка ймовірність отримати такі ж результати чисто випадково?".

- Якщо p <= 0.05 - результат вважають статистично значущим (зв'язок є, це не випадковість)
- Якщо p > 0.05 - результат вважають незначущим (зв'язок не доведений, це може бути випадковий збіг)

у нас значення p = 0.439, зв'язок не є доведеним.

V Крамера = 0.3. За таблицею Коена, це вказує на те, що зв'язок між двома колонками є середнім:

Effect size	small	medium	large
Standardized mean difference: d, g, Δ	≤ .20	.50	≥ .80
ANOVA: η^2	≤ .01	.06	≥ .14
Chi-square: ω^2	≤ .01	.06	≥ .14
Ch-square: V, φ	≤ .10	.30	≥ .50
Correlation: r, ρ	≤ .10	.30	≥ .50
Correlation: r^2	≤ .01	.09	≥ .25
Simple regression: β	≤ .10	.30	≥ .50
Multiple regression: β	≤ .20	.50	≥ .80
Multiple regression: R^2	≤ .02	.13	≥ .26
Odds ratio: OR	≤ 1.5	2.5	≥ 4.0
Hazar ratio: HR	≤ 1.3	1.7	≥ 2.5

In [447…

```
from scipy.stats import pearsonr

пара = df[['Стать', 'ступінь КТ']].dropna()
ступінь = пара['ступінь КТ'].astype(str).map(PIBHI_KT.index)

r1, p1 = pearsonr(пара['Стать'].map({'ж': 0, 'ч': 1}), ступінь)
r2, p2 = pearsonr(пара['Стать'].map({'ж': 1, 'ч': 0}), ступінь)

print("Кодування статті (ч=1, ж=0)")
print(f"r (корел. Пірсона) = {r1:.2f}, p = {p1:.2f}\n")
print("Кодування статті (ч=0, ж=1)")
print(f"r (корел. Пірсона) = {r2:.2f}, p = {p2:.2f}")
```

```
Кодування статті (ч=1, ж=0)
r (корел. Пірсона) = -0.13, p = 0.41

Кодування статті (ч=0, ж=1)
r (корел. Пірсона) = 0.13, p = 0.41
```

Висновок: Ми закодовували статті по різному і отримали різний коефіцієнт кореляції (r1, r2).

У першому випадку r1 = -0.13 , у другому r2 = +0.13.

Загалом знак кореляції вказує на те як змінюються одне відносно одного ознаки:

- Позитивна кореляція (r > 0): Змінні рухаються в одному напрямку. Якщо росте одна, росте й інша.
- Негативна кореляція (r < 0): Змінні рухаються в протилежних напрямках. Якщо одна росте, інша зменшується.
- Відсутність зв'язку (r = 0): Зміни однієї змінної ніяк не пов'язані зі змінами іншої.

У нас змінна "Стать" - номінальна шкала. "ж" не може бути більшою чи меншою за "ч". Як бачимо, закодувавши по-різному ці статті маємо різні результати. Це безглуздо. Тому кореляцію Пірсона тут не доречно застосовувати.

В обох випадках p = 0.41 > 0.05, тобто навіть сам факт зв'язку не підтверджений. Правильна міра для пари «номінальна × порядкова» — V Крамера, яка не залежить від кодування.

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

In [448…

```
ПІДГОТОВКА = {
    'Телефон': 'Вилучаємо з моделі: ідентифікатор, унікальний для кожного пацієнта',
    'Стать': 'One-hot: номінальна шкала',
    'ступінь КТ': 'Впорядкована категорія з явно заданим порядком легкий<…<критичний -> коди 0–4',
    'Виписка': 'Переходимо до тривалості госпіталізації «Виписка – Поступлення» і стандартизуємо в днях',
    'КТ': 'Діапазони зводимо до одного числа у % (середина діапазону), ділимо на 100. Нормалізації не треба до
    'Т вище 37,5': 'Беремо ціле число нормалізуємо через min-max (найменша кількість днів (1) стає 0, найбільша
    'Сечов2': 'Логарифм (бо є скошення даних), потім стандартизація через z-score',
    'БРпр1': 'Стандартизація через z-score'
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

Out[448…

	Стовпець	Шкала	Як готуємо
0	Телефон	Ідентифікатор	Вилучаємо з моделі: ідентифікатор, унікальний для кожног…
1	Стать	Номінальна	One-hot: номінальна шкала
2	ступінь КТ	Порядкова	Впорядкована категорія з явно заданим порядком легкий<…<…
3	Виписка	Інтервальна	Переходимо до тривалості госпіталізації «Виписка − Посту…
4	КТ	Відношень	Діапазони зводимо до одного числа у % (середина діапазон…
5	Т вище 37,5	Абсолютна	Беремо ціле число нормалізуємо через min-max (найменша к…
6	Сечов2	Відношень	Логарифм (бо є скошення даних), потім стандартизація чер…
7	БРпр1	Відношень	Стандартизація через z-score

In [449…

```
до = df[['Стать', 'ступінь КТ', 'Т вище 37,5']]
після = pd.DataFrame(index=df.index)


після['Стать_ч'] = pd.get_dummies(df['Стать'], dtype=int)['ч']

після['ступінь КТ'] = df['ступінь КТ'].cat.codes.replace(-1, np.nan)

т = df['Т вище 37,5']
після['Т вище 37,5'] = (т - т.min()) / (т.max() - т.min())

print('ДО перетворення')
display(до.head(8))
print('ПІСЛЯ перетворення')
display(після.head(8))
```

ДО перетворення

	Стать	ступінь КТ	Т вище 37,5
0	ч	середній	3.0
1	ч	середній	3.0
2	ж	критичний	3.0
3	ж	критичний	6.0
4	ж	NaN	5.0
5	ж	середній	NaN
6	ч	важкий	NaN
7	ж	легкий	NaN

ПІСЛЯ перетворення

	Стать_ч	ступінь КТ	Т вище 37,5
0	1	1.0	0.153846
1	1	1.0	0.153846
2	0	4.0	0.153846
3	0	4.0	0.384615
4	0	NaN	0.307692
5	0	1.0	NaN
6	1	2.0	NaN
7	0	0.0	NaN

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний `NaN` замість помилки.

In [450…

```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення на нуль')
    elif len(з) and з.max() == з.min():
```

```
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

In [451…

```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`**. Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

In [452…

```
ВИПРАВЛЕННЯ = [
    (1,'Середнє від номінальної змінної «помер/жив»', 'Пацієнт посередині між смертю і одужанням» не існує','Д

    (2,'Неочищені дані ','Одна категорія записана по-різному («ж»/«жін», «ч»/«чол»), тому маємо 4 статті замість

    (3,'Порядкову змінну впорядковано за алфавітом, не очищено від описок, а потім пораховано середнє від довіл

    (4,"Відкинуто усі текстові записи: pd.to_numeric(df['КТ'], errors='coerce')",'Середнє пораховано лишень на

    (5,'У сатурації змішано формати: одне значення записане часткою (0.9 замість 90 %), і його не виправлено',
     'Висновок «у більшості пацієнтів» зроблено із середнього, яке не описує «більшість»',
     'Перевести значення відсотки: мінімум 50 %. Про «більшість» говорити через медіану і квартилі'),

    (6,'Коефіцієнт варіації для дат','CV = std / mean, а «середнє» дати залежить від точки відліку', 'Відмовити

    (7, 'Пірсон між двома номінальними змінними (стать і результат), закодованими довільно числами 0/1.','Знак

    (8, 'Min-max застосовано наосліп до всіх числових стовпців: до коду «помер/жив» (номінальна) і до стовпців
     'Нормалізований код «помер/жив» не має змісту. У колонці Ферит2 тільки 1 занчення зі 121, треба виключити

    (9, 'dropna() по всіх стовпцях','Залишилось 0 рядків із 121 - «повністю заповнений набір, придатний для мод

    (10, 'Витік цільової змінної: «Дата розтину» існує лише в померлих, тобто є наслідком результату','r = 1.00
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із 10'
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть усі чотири поля'
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення закороткі'

pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число неправильне', 'Як правильно'])
```

Out[452...

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1	Середнє від номінальної змінної «помер/жив»	Пацієнт посередині між смертю і одужанням» не існує	Для номінальної шкали - частоти і мода
1	2	Неочищені дані	Одна категорія записана по-різному («ж»/«жін», «ч»/«чол»...	Уніфікувати записи (чол=ч, жін=ж) і лише потім рахувати ...
2	3	Порядкову змінну впорядковано за алфавітом, не очищено в...	«Найлегший - важкий, найважчий - середній» звучить нелог...	Звести описки до 5 рівнів, задати порядок легкий<середні...
3	4	Відкинуто усі текстові записи: pd.to_numeric(df['КТ'], e...	Середнє пораховано лишень на малій підвибірці	Спершу опрацювувати діапазони (взяте середнє) і перевест...
4	5	У сатурації змішано формати: одне значення записане част...	Висновок «у більшості пацієнтів» зроблено із середнього,...	Перевести значення відсотки: мінімум 50 %. Про «більшіст...
5	6	Коефіцієнт варіації для дат	CV = std / mean, а «середнє» дати залежить від точки від...	Відмовитись від CV тут. Для дат - кількість госпіталізац...
6	7	Пірсон між двома номінальними змінними (стать і результа...	Знак r залежить від кодування, кореляція Пірсона не підх...	Побудувати таблицю спряженості і порахувати chi2 та V Кр...
7	8	Min-max застосовано наосліп до всіх числових стовпців: д...	Нормалізований код «помер/жив» не має змісту. У колонці ...	Нормалізувати лише кількісні ознаки, попередньо перевіри...
8	9	dropna() по всіх стовпцях	Залишилось 0 рядків із 121 - «повністю заповнений набір,...	Видаляти рядки тільки за умови відсутності запису в потр...
9	10	Витік цільової змінної: «Дата розтину» існує лише в поме...	r = 1.00 означає не «найкращий предиктор», а що ознака і...	Виключити ознаки, які відомі лише після смерті і оцінюва...

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [453...

```
сирі = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')


print('Розподіл за статтю')
print('НЕПРАВИЛЬНО: статей —', сирі['Стать'].nunique())
print(сирі['Стать'].value_counts().to_string())

стать_ок = сирі['Стать'].apply(стать)
print('\nПРАВИЛЬНО: статей —', стать_ок.nunique())
print(стать_ок.value_counts().to_string())


print('\nОбсяг ураження легень')
кт_погано = pd.to_numeric(сирі['КТ'], errors='coerce')
print(f'НЕПРАВИЛЬНО: значень {кт_погано.notna().sum()} з 44, '
      f'середнє {100 * кт_погано.mean():.1f} %, медіана {100 * кт_погано.median():.1f} %')

кт_добре = сирі['КТ'].apply(кт)
print(f'ПРАВИЛЬНО:   значень {кт_добре.notna().sum()} з 44, '
      f'середнє {кт_добре.mean():.1f} %, медіана {кт_добре.median():.1f} %')


print('\nОчищення від пропусків')
print('НЕПРАВИЛЬНО: dropna() по всіх стовпцях — залишилось',
      len(сирі.dropna()), 'рядків з', len(сирі))

потрібні = ['Стать', 'ступінь КТ']
print('ПРАВИЛЬНО:   dropna лише по', потрібні, '— залишилось',
      len(сирі.dropna(subset=потрібні)), 'рядків')
```

```
Розподіл за статтю
НЕПРАВИЛЬНО: статей — 4
Стать
ж      56
ч      34
жін    19
чол    12

ПРАВИЛЬНО: статей — 2
Стать
ж    75
ч    46

Обсяг ураження легень
НЕПРАВИЛЬНО: значень 27 з 44, середнє 39.6 %, медіана 30.0 %
ПРАВИЛЬНО:   значень 43 з 44, середнє 42.5 %, медіана 35.0 %

Очищення від пропусків
НЕПРАВИЛЬНО: dropna() по всіх стовпцях — залишилось 0 рядків з 121
ПРАВИЛЬНО:   dropna лише по ['Стать', 'ступінь КТ'] — залишилось 42 рядків
```

Етап 7. Висновки та індивідуальне питання

In [454…

```python
ВИСНОВКИ = [
'Статистику треба обирати відповідно до шкали: для ступеня КТ (порядкова шкала) середнє не підходить, тому бере
'Перед аналізом дані треба очистити: стать мала 4 варіанти запису замість 2, а ступінь КТ - 12 написань замість
'Тип у pandas не відповідає шкалі: КТ і дні температури зберігались як текст, хоча це кількісні величини',
'Для оцінки сили зв\'язку між статтю (номінальна) та ступенем КТ (порядкова) не підходить кореляція Пірсона: її
]

assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

```
1. Статистику треба обирати відповідно до шкали: для ступеня КТ (порядкова шкала) середнє не підходить, тому бе
реться медіана, а для статі (номінальна шкала) можна рахувати лише частоти й модуПеред аналізом дані треба очис
тити: стать мала 4 варіанти запису замість 2, а ступінь КТ - 12 написань замість 5
2. Тип у pandas не відповідає шкалі: КТ і дні температури зберігались як текст, хоча це кількісні величини
3. Для оцінки сили зв'язку між статтю (номінальна) та ступенем КТ (порядкова) не підходить кореляція Пірсона: ї
ї знак залежить від способу кодування статі. Натомість V Крамера рахується з таблиці спряженості і від кодуванн
я не залежить
```

In [455…

```python
print('ВАШЕ ПИТАННЯ:'); print(B['питання']); print()
ВІДПОВІДЬ = "Стать і результат лікування («помер/жив») — обидві змінні номінальні: їхні значення є лише мітками
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою (від 200 символів)'
print(ВІДПОВІДЬ)
```

```
ВАШЕ ПИТАННЯ:
Чому не можна обчислити коефіцієнт кореляції Пірсона між статтю та результатом лікування? Яку міру зв’язку слід
узяти замість нього?

Стать і результат лікування («помер/жив») — обидві змінні номінальні: їхні значення є лише мітками категорій, а
не числами. Коефіцієнт Пірсона вимагає кількісних змінних, для яких мають сенс середні. Щоб його порахувати, ка
тегорії доводиться закодувати числами, але це кодування довільне: якщо поміняти коди місцями, знак кореляції пе
ревернеться, тобто «прямий» чи «обернений» зв'язок визначає наш вибір, а не дані. Замість нього слід побудувати
таблицю спряженості «стать × результат» і застосувати критерій χ² та коефіцієнт V Крамера. Ці міри працюють лиш
е з частотами в клітинках і не залежать від того, як названо категорії.
```

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті
- `'текст, як є'` — згенерований текст залишено майже без змін

In [456…

```
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':         'ні',
    'етап 2 — допустимі статистики':    'ні',
    'етап 3 — безглузді числа':         'код, перевірено',
    'етап 4 — міра зв’язку':            'код, перевірено',
    'етап 5 — підготовка до моделі':    'код, перевірено',
    'етап 6 — виправлення аналізу':     'текст, перероблено',
    'етап 7 — висновки й відповідь':    'ні',
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = 'Кожну клітинку запускала сама і перевіряла, що результат має сенс: що після очищення нем
ПІДТВЕРДЖУЮ = True      # я можу пояснити кожен рядок свого коду
                        # і внести в нього зміни на вимогу під час захисту
```

In [457…

```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст, перероблено', 'текст, як є'}

перевірки = {
    'заповнено титульні поля':         bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР),
    'етап 1: паспорт із 8 стовпців':   all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1] for c in МОЇ),
    'етап 3: три безглузді числа':     len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40),
    'етап 5: підготовку описано':      all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ),
    'етап 6: знайдено 10 помилок':     len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':            len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':    len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':            all(v in ФОРМУЛЮВАННЯ for v in ДЕКЛАРАЦІЯ.values()),
    'опис перевірки ≥ 120 символів':   len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >= 120,
    'підтвердження авторства':         ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-лист вище'
print()
print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
====================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  ГОТОВО     опис перевірки ≥ 120 символів
  ГОТОВО     підтвердження авторства
====================================================

Робота варіанта 15 готова до захисту.
Паничевська Ярина Ернестівна, ШІ-32
```

Перед здачею

Виконайте **Kernel → Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.